

Récupération de fichiers dans un espace de stockage

Après la perte de certains fichiers importants sur mon disque dur, j'ai tenté de les récupérer. Lors de mes recherches, je me suis rendu compte que les fichiers n'étaient pas réellement supprimés, seul l'accès à ces derniers l'était. Nous nous sommes donc intéressés au processus de récupération des fichiers.

En plus de l'intérêt théorique et pratique de ces recherches, elles s'inscrivent dans le thème de l'année par la transformation de ces données brutes en fichiers utilisables. Cela nécessite l'accès au disque dur puis le traitement de ses données pour enfin reconstituer nos fichiers perdus.

Le candidat déclare avoir travaillé en groupe avec

- 24671 GUERIN-GARNIER William

Positionnement thématique (ÉTAPE 2) :

- INFORMATIQUE (*Informatique pratique*)

Mots-clés (ÉTAPE 1) :

Mots-clés (en français)

Restauration de Fichiers

Simulation d'un système de fichier

Algorithmes de recherche

Lecture séquentielle

Base de données

Mots-clés (en anglais)

file-system simulation

Search algorithm

Sequential reading

Database

File carving

Bibliographie commentée

Notre TIPE porte sur la récupération de fichiers supprimés d'une mémoire brute. Cette problématique découle de la capacité à accéder à des données dites supprimées, qui subsistent malgré l'effacement de leur accès dans le système de fichiers [1]. L'objectif principal est de récupérer des données d'un disque dur, qu'il soit virtuel ou réel, permettant de reconstituer des fichiers de cet espace où les métadonnées auraient été effacées [2].

Une fois les données obtenues, la récupération des fichiers repose sur une analyse séquentielle des données brutes. En identifiant les entêtes caractéristiques de différents formats de fichiers [3], il devient possible de reconstituer des fichiers tels que des images ou des documents texte. Ce procédé, le "file carving", nous a amenés à concevoir des algorithmes capables de reconnaître les structures caractéristiques de formats comme JPEG, PNG et GIF [4]. Ces algorithmes détectent les blocs de données correspondants aux signatures hexadécimales spécifiques.

Par ailleurs, une attention particulière a été portée à la validation des fichiers reconstitués. Après extraction, chaque fichier est testé afin de vérifier son intégrité et sa conformité avec son format attendu [5]. On pourra aussi comparer l'efficacité de nos algorithmes face aux logiciels professionnels de récupération de fichiers comme TestDisk, Recuva ou Photorec pour mesurer les différences en termes de taux de récupération, vitesse d'exécution et précision des fichiers retrouvés [6]. Cette phase est essentielle pour évaluer la robustesse de nos algorithmes et leur capacité à gérer des données corrompues ou partielles.

Malgré tout, une étape primordiale reste difficile : la récupération de données. Pour résoudre cela, nous avons créé une simulation d'un système de fichiers. Les fichiers sont convertis en leur représentation hexadécimale, et leurs informations de stockage sont inscrites dans une table de base de données SQL [8]. Cela permet d'obtenir une mémoire brute virtuelle en TXT accessible après suppression de la base SQL. Cette étape de simulation garantit un environnement contrôlé, propice à la mise en œuvre et à l'évaluation des algorithmes de récupération.

Enfin, notre projet met également en lumière les enjeux de sécurité liés à la récupération de fichiers. Il illustre l'importance de méthodes efficaces de suppression définitive des données pour prévenir tout accès non autorisé. Cette réflexion renforce l'intérêt de notre TIPE, qui combine une approche technique rigoureuse et une portée applicative pertinente dans le domaine de la gestion des données numériques.

Problématique retenue

La récupération des fichiers supposément perdus à partir des données brutes d'un espace de stockage est-elle théoriquement possible et aussi réalisable en pratique ?

Objectifs du TIPE des candidats

Objectifs William	Objectifs Clément
1 Comprendre la gestion des fichiers en mémoire et l'utilité des méta-données.	Comprendre la gestion des fichiers en mémoire et l'utilité des méta-données.
2 Tester la récupération sur un vrai système de données (clé USB ou disque dur) avec des partitions supprimées pour comparer les performances avec des outils existants.	Créer une simulation de mémoire brute : développer un simulateur basé sur une base SQL représentant une clé USB.
3 Développer des algorithmes de récupération : écrire des algorithmes permettant d'extraire et reconstruire différents types de fichiers à partir de données hexadécimales (JPEG, PNG, GIF).	Tester la récupération sur un vrai système de données (clé USB ou disque dur) avec des partitions supprimées pour comparer les performances avec des outils existants.
4 Tester la robustesse des algorithmes : évaluer leur performance dans différents scénarios (absence de métadonnées, fichiers artificiellement corrompus).	Tester la robustesse des algorithmes : évaluer leur performance dans différents scénarios (absence de métadonnées, fichiers artificiellement corrompus).
5 Apporter une réflexion sur la sécurité des données : étudier les implications pratiques de ces techniques pour la confidentialité des données supprimées.	Apporter une réflexion sur la sécurité des données : étudier les implications pratiques de ces techniques pour la confidentialité des données supprimées.

Références bibliographiques (ÉTAPE 1)

- [1] STEVEN ALEXANDER : *Understanding Deleted Files and What They Mean* : <https://www.hgexperts.com/expert-witness-articles/understanding-deleted-files-and-what-they-mean-44950>
- [2] GOLDEN RICHARD III : *Scalpel: A Frugal, High Performance File Carver* : <https://dfrws.org/presentation/scalpel-a-frugal-high-performance-file-carver/>
- [3] GARY KESSLER : *GCK'S FILE SIGNATURES TABLE* : https://www.garykessler.net/library/file_sigs.html

- [4] ROYAL E. FRAZIER JR. : *All About GIF89a* : <https://web.archive.org/web/19990418091037/http://www6.uniovi.es/gifanim/gifabout.htm>
- [5] KEVIN ENGEL : *Comment vérifier l'intégrité d'un fichier ?* : <https://www.tech2tech.fr/comment-verifier-lintegrite-dun-fichier/>
- [6] THOMAS LAURENSEN : *Performance Analysis of File Carving Tools* : <https://inria.hal.science/hal-01463843/document>
- [7] ANDREW S. TANENBAUM, HERBERT BOS : *Modern Operating Systems* : <http://stst.elia.pub.ro/news/SO/Modern%20Operating%20System%20-%20Tanenbaum.pdf>
- [8] NIKITA PATEL ET AL. : *SQL Injection Attacks: Techniques and Protection Mechanisms* : <https://www.academia.edu/download/101022407/IJCSE11-03-01-139.pdf>

DOT

- [1] : *Novembre 2024 - Choix du sujet : Découverte des possibilités de récupération de fichiers effacés sur disque. Recherches initiales sur les formats JPEG et PNG. Lecture d'articles sur les signatures hexadécimales de fichiers.*
- [2] : *Décembre 2024 - Extraction mémoire brute : Développement d'un script Python pour lire une mémoire brute et identifier les headers de fichiers types (JPEG, PNG). Test sur un fichier simulé fichier_hexadecimal.txt.*
- [3] : *Janvier 2025 - Simulation de stockage : Implémentation d'un système de stockage avec table d'allocation simplifiée en SQLite. Construction manuelle de la base de données simulée.*
- [4] : *Février 2025 - Détection d'anomalies : Échecs répétés sur l'identification des fichiers vidéo MOV à cause de signatures tronquées. Réorientation du travail vers les formats image uniquement.*
- [5] : *Mars 2025 - Création interface : Création d'une interface minimale pour afficher les fichiers extraits. Ajout de contrôles anti-injection SQL après tests avec DROP TABLE.*
- [6] : *Avril 2025 - Récupération d'arborescence : Ajout d'un système de répertoires simulés pour représenter une arborescence. Implémentation des métadonnées dans la base SQLite.*
- [7] : *Mai 2025 - Finalisation : Préparation du diaporama, mise en forme des codes pour l'annexe, tests finaux sur simulation complète.*